

Chaque jour, vous jetez de l'argent à la poubelle.

SmartStock LA solution dont VOUS restaurateurs avez besoin!





Un dilemme quotidien et coûteux

1,5M

Tonne de gaspillage/an

200K

Restaurateurs sans outil

15-20%

De la masse salariale

SmartStock : L'agent qui vous aide à décider

Fini les commandes fixes

Les estimations manuelles sont imprécises et souvent sources de surstock ou de ruptures.

Commandes intelligentes et adaptées

Notre IA prédit la demande et ajuste vos approvisionnements avec une précision chirurgicale.



Adaptation quotidienne



Réduction du gaspillage




Meilleur service client

Un agent qui apprend de vos ventes pour **vous aider à optimiser vos commandes** et votre rentabilité.




De Q-Learning à DQN : Adapter le modèle à la réalité



Critère	Q-Learning Tabulaire	Deep Q-Network (DQN)
Nombre de produits	1 produit	3+ produits
Taille de l'espace d'états	5 733 cases	Généralisation par réseau
Temps de convergence	500 épisodes (5 sec)	1 500 épisodes (stable)
Taux de rupture	3,3%	7,8%
Taux de service	Excellent sur 1 produit	92% multi-produits
Scalabilité	Explose en mémoire	Généralise
Complexité	Simple	Réseau de neurones

Pourquoi le Reinforcement Learning pour SmartStock?




Notre modélisation MDP

Les 4 composantes du MDP traduisent directement la réalité opérationnelle d'un restaurant indépendant.

- **État** : Stock par produit, jours avant péremption, demande récente, jour de la semaine — ce que le chef voit chaque matin
- **Action** : Quantité à commander par produit — ce que le chef décide
- **Récompense** : Ventes réalisées – pénalité gaspillage – pénalité rupture, asymétriques par produit (jeter du saumon coûte plus cher que du pain, mais une rupture de pain frustre plus de clients)

Résultats & Comparaison



L'équilibre optimal

L'agent trouve ce que les politiques fixes ne peuvent pas atteindre :
autant de clients servis que la politique agressive, mais **3× moins de gaspillage**.

📄 **Ce qui le prouve** : 550 portions servies (vs 543 en agressif) avec seulement 26 jetées (vs 72).

26 portions jetées

Contre 72 en commande agressive

Démo



Limites identifiées et perspectives

→ Données simulées vs données réelles


→ Produits simplifiés

→ Temps de convergence


Merci!

Merci pour votre écoute


Parametres de recompense par produit



Recompense selon la quantite commandee (demande fixe = 5 portions)



Asymetrie des penalites (rapportees a la marge)



DQN :

Hyperparamètre	Valeur	Pourquoi
Architecture	MLP 22→128→128→729	2 couches cachées, suffisant pour ce problème
γ (discount)	0.90	Court terme comme Q-learning, légèrement plus haut car multi-produits
lr (learning rate)	5e-4	Plus bas que 1e-3 pour stabiliser
Batch size	128	Gros batch = gradients stables sur 729 actions
Replay buffer	30 000 transitions	Casse la corrélation temporelle
Target network update	Tous les 500 pas	Cible stable, moins d'oscillations
ϵ start	1.0	Exploration totale au début
ϵ end	0.05	5% exploration résiduelle
ϵ decay	0.995	Décroissance par épisode
Épisodes	1500	Convergence vers 1000
Loss	Huber (SmoothL1)	Plus robuste que MSE aux outliers
Gradient clipping	Norme max 10.0	Empêche les explosions de gradient
Optimiseur	Adam	Standard pour le deep RL