

Hackathon Deep Q-Learning

Deux journées intensives pour passer du Q-Learning tabulaire au Deep Q-Network (DQN), comparer leurs performances et concevoir une solution RL techniquement cohérente et pertinente du point de vue métier.

📋 Objectif : performance algorithmique · qualité de modélisation · valeur business

📅 MARDI & JEUDI

👤 ÉQUIPES DE 2-3

🕒 9H00 - 17H00

Choix du projet : idées de situations possibles

Les équipes peuvent choisir librement leur environnement, à condition qu'il soit simulé, faisable dans le temps imparti, pertinent pour comparer Q-Learning et DQN, et défendable sur le plan technique et métier.



Robot naviguant

Dans une grille avec obstacles



Snake simplifié

Classique du jeu vidéo



Feux de circulation

Gestion à une intersection



Gestion énergétique

Simplifiée d'un bâtiment



Agent livreur

Dans une grille optimisée



CartPole ou variante

Environnement de contrôle



Autre environnement

Simple, simulé, bien modélisé

📄 Les thèmes ci-dessus sont des exemples. Le choix final est libre s'il reste cohérent, implémentable et justifié.

Comment choisir un bon sujet de hackathon RL ?



Faisabilité technique

Environnement simple, simulation rapide, état et action clairement définis



Richesse RL

Présence d'un vrai signal de récompense, d'un arbitrage et d'une stratégie apprenable



Comparabilité

Permet une comparaison honnête entre approche tabulaire et approche neuronale, ou justifie pourquoi le DQN devient nécessaire



Valeur business

Répond à une logique métier identifiable : réduction de coût, amélioration de performance, gain de temps, robustesse opérationnelle, aide à la décision

📌 Un bon projet de hackathon ne se contente pas de 'faire tourner un agent' : il doit montrer pourquoi cette approche pourrait être utile dans un contexte réel.

Accueil et objectifs du hackathon

Deux journées pour maîtriser la transition du Q-Learning tabulaire vers le Deep Q-Learning et en comparer rigoureusement les performances sur un environnement choisi et correctement modélisé.

Objectif principal

Passer du Q-Learning tabulaire au Deep Q-Learning (DQN), puis comparer les deux approches sur un environnement choisi et correctement modélisé.

Ce qui sera évalué

- Compréhension du MDP
- Qualité de la modélisation RL
- Implémentation des algorithmes
- Analyse comparative des résultats
- Capacité à faire émerger une valeur business claire

❏ Le but n'est pas seulement d'obtenir un agent fonctionnel, mais de proposer une solution techniquement défendable et utile dans un cadre métier simulé.



Q-Table



DQN

Sprint 1 – Modélisation et Q-Learning



Choix du projet et cadre MDP

Choisir un environnement simulé pertinent et définir précisément : les états, les actions, les récompenses, les transitions et la logique métier associée.



Discrétisation et hyperparamètres

Discrétiser les états si nécessaire pour construire la Q-table. Choisir les hyperparamètres clés : alpha (taux d'apprentissage), gamma (discount), epsilon (exploration).



Première implémentation

Coder le Q-Learning tabulaire et lancer les premiers tests pour observer la convergence et les premières limites du modèle.

📌 Point d'attention : dès cette phase, chaque équipe doit être capable d'expliquer en quoi son problème possède un intérêt métier ou opérationnel.

Sprint 2 – Passage au Deep Q-Network

Architecture DQN

Le DQN repose sur un réseau MLP qui prend l'état en entrée et produit une valeur Q pour chaque action possible. Il remplace la Q-table lorsque l'espace d'états devient trop riche, trop continu ou trop grand.

Mécanismes de stabilisation

Experience Replay – Target Network

Enjeu métier

Montrer pourquoi une approche plus expressive que la Q-table peut devenir nécessaire pour mieux capturer la complexité d'un problème plus réaliste.

- ❏ Le passage au DQN doit être justifié par un besoin de généralisation, pas seulement par effet de mode.

Sprint 3 – Implémentation, tests et première lecture métier

Implémentation complète

Programmer le DQN de bout en bout et démarrer l'entraînement sur l'environnement choisi.

Ajustement des hyperparamètres

Affiner le taux d'apprentissage, l'epsilon decay et la fréquence de mise à jour du réseau cible.

Comparaison initiale

Comparer les premiers résultats du DQN avec ceux du Q-Learning : récompense, stabilité, vitesse de progression, capacité de généralisation.

Lecture métier attendue

Interpréter les résultats en termes d'impact possible sur un usage réel : meilleure robustesse, meilleure adaptation, décision plus efficace, réduction d'erreurs.

Livrables attendus – Jour 1



Q-table fonctionnelle

Algorithme de Q-Learning tabulaire implémenté, testé et analysé sur l'environnement choisi.



DQN opérationnel

Deep Q-Network fonctionnel intégrant replay buffer et target network.



Courbes et premières observations

Récompenses, comportements observés, problèmes rencontrés, stabilité initiale.



Justification business initiale

Première formulation claire de la valeur potentielle du projet : quel problème métier est simulé, pourquoi ce sujet est utile, et quel type de gain ou d'amélioration l'approche RL pourrait apporter.

Critères de réussite du hackathon

Compréhension du problème RL

Maîtrise des concepts MDP, Q-Learning, DQN et de leurs fondements théoriques.

Qualité de la modélisation MDP

Définition rigoureuse des états, actions, récompenses et transitions.

Qualité de l'implémentation et des tests

Code propre, modulaire, fonctionnel et reproductible.

Analyse comparative Q-Learning vs DQN

Interprétation critique des résultats, des limites et des différences observées.

Valeur business

Capacité à montrer à quel besoin réel le projet pourrait répondre, pourquoi le RL est pertinent ici, ce que la solution améliore concrètement, et quelles seraient ses limites dans un contexte réel.

📌 Un bon projet de hackathon RL ne se limite pas à une démonstration algorithmique : il articule technique, analyse et intérêt métier.